

HU-SPIKE – Delimitación del alcance del estudio comparativo entre destilación *baseline* y destilación con *teacher* RAG

Documento de síntesis, comparación y recomendación técnica

Autor	Andrés Pérez Quicnhía	Fecha	22/03/2026
Sprint	1	Estado	Done

1. Descripción de la HU

Como investigador, **quiero** delimitar el alcance del estudio comparativo entre destilación *baseline* y destilación con *teacher* RAG, **para** asegurar que ambos enfoques sean comparables y el experimento sea científicamente válido.

2. Objetivo de la HU

Definir un marco experimental riguroso que permita comparar de forma justa la destilación de conocimiento en su variante *baseline* (*teacher* estándar) frente a una variante donde el *teacher* está aumentado con *Retrieval-Augmented Generation* (RAG), de modo que el equipo pueda establecer con precisión qué variables se controlan, qué componentes permanecen constantes y cuáles se modifican entre ambos enfoques, asegurando que cualquier diferencia en los resultados pueda atribuirse exclusivamente al uso (o no) de RAG en el *teacher*.

3. Contexto

El proyecto busca comparar una destilación *baseline* contra una destilación guiada por un *teacher* con RAG. Para que esa comparación tenga validez científica, no basta con ejecutar ambos pipelines y contrastar resultados: es necesario un diseño experimental controlado que aísle el efecto del componente RAG sobre la calidad del *student* destilado.

En la destilación de conocimiento (*knowledge distillation*), un modelo *teacher* de mayor capacidad transfiere su conocimiento a un modelo *student* más pequeño. El enfoque *baseline* utiliza un *teacher* que responde exclusivamente desde sus parámetros internos. El enfoque con RAG aumenta al *teacher* con un sistema de recuperación que le proporciona contexto externo antes de generar la respuesta.

El problema central es que si se varían múltiples componentes simultáneamente (modelo base, datos de entrenamiento, hiperparámetros, métricas), resulta imposible determinar si las diferencias de rendimiento del *student* se deben al RAG o a otros factores.

Esta HU se enfoca en tomar una decisión documentada: delimitar con precisión el alcance experimental, definir qué se controla y qué varía, y justificar técnicamente esas decisiones.

4. Criterios de aceptación

Código	Criterio
CA1	Debe existir un documento de síntesis que describa claramente el alcance, los objetivos y los supuestos adoptados para el estudio comparativo entre <i>baseline</i> y RAG.
CA2	Debe existir una matriz de decisión que especifique qué componentes se mantienen constantes y cuáles varían entre ambos enfoques.
CA3	Debe quedar explícitamente documentada una decisión justificada sobre el alcance final del experimento.
CA4	Deben incluirse fuentes académicas y técnicas que respalden las decisiones metodológicas tomadas.

5. Análisis comparativo

Se analizaron tres enfoques de diseño experimental para delimitar el alcance de la comparación entre destilación *baseline* y destilación con *teacher* RAG. El objetivo no es elegir una técnica de destilación, sino definir cómo estructurar el experimento para que la comparación sea válida.

5.1. A. Control por variables fijas

El enfoque de control por variables fijas consiste en mantener constantes todos los componentes del pipeline de destilación excepto uno: la presencia o ausencia de RAG en el *teacher*. Esto implica que el modelo *student*, el dataset de entrenamiento, los hiperparámetros de destilación (temperatura, alpha, learning rate), la función de pérdida y las métricas de evaluación permanecen idénticos en ambas condiciones experimentales. La única variable independiente es si el *teacher* utiliza RAG para generar sus respuestas o no.

Su principal ventaja es la alta validez interna: cualquier diferencia observada en el rendimiento del *student* puede atribuirse directamente al efecto del RAG. Además, es el diseño más simple de implementar y analizar, ya que solo requiere dos condiciones experimentales. Su limitación es que no explora interacciones entre factores; por ejemplo, no revela si el RAG funcionaría mejor con una temperatura diferente o un dataset más grande.

5.2. B. Diseño factorial

El diseño factorial explora sistemáticamente las combinaciones de múltiples factores. En este contexto, podrían variarse simultáneamente la presencia de RAG, la temperatura de destilación, el tamaño del dataset y el tipo de métricas, ejecutando experimentos para cada combinación posible. Esto permite identificar no solo efectos principales sino también interacciones entre factores.

Su fortaleza es la granularidad: proporciona un mapa completo del espacio de diseño y permite detectar combinaciones óptimas. Sin embargo, su principal desventaja es el costo computacional: un diseño factorial completo con k factores y n niveles requiere n^k ejecuciones, lo que escala exponencialmente. Para un proyecto con recursos limitados, esto resulta inviable en la mayoría de configuraciones. Además, añade complejidad al análisis estadístico y puede dificultar la interpretación de resultados cuando hay muchos factores.

5.3. C. Ablation study

El *ablation study* consiste en partir de un sistema completo y remover o modificar componentes de forma sistemática para medir su contribución individual. Aplicado al contexto del proyecto,

se partiría del pipeline completo con RAG y se irían eliminando o sustituyendo componentes (el retriever, el reranker, el contexto inyectado) para observar cómo cambia el rendimiento del *student*.

Este enfoque es útil para entender la contribución marginal de cada componente, lo cual lo hace valioso como estudio complementario. Sin embargo, como diseño principal para la comparación *baseline* vs. RAG presenta limitaciones: no garantiza control simultáneo de todas las variables, y su interpretación depende del orden en que se realizan las ablaciones. Es más adecuado como validación posterior que como marco experimental primario.

Matriz de comparación

5.4. Alternativas consideradas

Código	Alternativa
A	Control por variables fijas
B	Diseño factorial
C	<i>Ablation study</i>

5.5. Comparación por criterios

Criterio	A	B	C	Observaciones
Complejidad de implementación	Baja	Alta	Media	A requiere solo dos condiciones; B escala exponencialmente; C es intermedio.
Validez interna	Alta	Alta	Media-Alta	A y B maximizan control; C depende del orden de ablación.
Escalabilidad	Media	Baja	Alta	B no escala bien con más factores; C se adapta a nuevos componentes.
Reproducibilidad	Alta	Alta	Alta	Todos son reproducibles si se documentan correctamente.
Recursos computacionales	Bajos	Altos	Medios	B requiere múltiples combinaciones; A solo dos ejecuciones.
Compatibilidad con el proyecto	Alta	Media	Alta	A y C se alinean mejor con los recursos y objetivos actuales del proyecto.

5.6. Síntesis de enfoques analizados

Control por variables fijas. Mantiene constantes todos los componentes del pipeline excepto la presencia de RAG en el *teacher*. Es la opción de menor costo de implementación y mayor validez interna para una comparación directa A/B. Su limitación es que no captura posibles interacciones entre el RAG y otros hiperparámetros del sistema.

Diseño factorial. Varía sistemáticamente múltiples factores para explorar el espacio de diseño completo. Ofrece máxima granularidad pero a un costo computacional que escala exponencialmente, lo que lo hace inviable en el contexto actual del proyecto.

Ablation study. Parte del sistema completo y remueve componentes para medir su contribución marginal. Es valioso como validación complementaria, pero insuficiente como marco experimental primario porque no garantiza control simultáneo de todas las variables y su interpretación depende del orden de las ablaciones.

5.7. Referencias consideradas

- R1** Hinton, G., Vinyals, O. & Dean, J. (2015). *Distilling the Knowledge in a Neural Network*. arXiv:1503.02531.
- R2** Gou, J. et al. (2021). *Knowledge Distillation: A Survey*. International Journal of Computer Vision, 129, 1789–1819.
- R3** Lewis, P. et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020.
- R4** Wu et al. (2024). *Retrieval-Augmented Generation for Natural Language Processing: A Survey*.
- R5** Montgomery, D. C. (2017). *Design and Analysis of Experiments* (9th ed.). Wiley.
- R6** Meyes, R. et al. (2019). *Ablation Studies in Artificial Neural Networks*. arXiv:1901.08644.
- R7** Hugging Face Transformers – Knowledge Distillation documentation.
- R8** LangChain – RAG Pipelines documentation.

6. Resultado / Conclusión

6.1. Hallazgos principales

- El control por variables fijas es el enfoque más adecuado para aislar el efecto del RAG en el *teacher*, ya que mantiene una única variable independiente y maximiza la validez interna.
- El diseño factorial ofrece mayor granularidad pero excede los recursos computacionales disponibles y añade complejidad innecesaria para la pregunta de investigación actual.
- El *ablation study* resulta útil como complemento posterior, pero no como marco experimental primario porque no garantiza control simultáneo de variables.
- La literatura de diseño experimental respalda consistentemente el uso de controles por variables fijas para comparaciones A/B de componentes específicos en pipelines de NLP.

6.2. Decisión técnica

Se adoptará el enfoque de **control por variables fijas** como diseño experimental del estudio comparativo. Esto implica que:

- **Componentes constantes:** modelo *student*, dataset de entrenamiento, hiperparámetros de destilación (temperatura, alpha, learning rate), función de pérdida (KL-divergence), métricas de evaluación y conjunto de test.
- **Variable independiente:** presencia o ausencia de RAG en el *teacher*.

- **Variable dependiente:** rendimiento del *student* destilado (medido con las métricas definidas).

La decisión se justifica porque: (1) maximiza la validez interna al aislar una única variable; (2) requiere recursos computacionales razonables (solo dos condiciones experimentales); (3) es consistente con las prácticas estándar de investigación en ML; y (4) deja preparada una ruta de mejora hacia un *ablation study* posterior si se requiere mayor detalle sobre componentes específicos del RAG.

En otras palabras, el diseño seleccionado no es el más exhaustivo posible, pero tampoco el más simplista. Es la mejor relación entre rigor metodológico, viabilidad computacional y valor experimental para el proyecto de destilación.

6.3. Impacto en el proyecto

- Permite responder directamente la pregunta central del proyecto: ¿mejora el rendimiento del *student* cuando el *teacher* utiliza RAG?
- Facilita la comparación experimental al definir claramente el grupo de control (*baseline*) y el grupo experimental (RAG).
- Mantiene trazabilidad y reproducibilidad del diseño para futuras iteraciones del pipeline.

6.4. Trade-offs

Qué se gana	Qué se sacrifica	Riesgos
Alta validez interna, simplicidad de implementación y análisis, bajo costo computacional y conclusiones atribuibles a una sola variable.	No se exploran interacciones entre factores, menor granularidad en resultados y conclusiones específicas a la configuración elegida.	Si existen interacciones no anticipadas entre el RAG y otros hiperparámetros, el diseño no las capturará. Se mitiga con <i>ablation study</i> posterior.

6.5. Nivel de confianza

Nivel de confianza: Alto. La decisión está respaldada por principios estándar de diseño experimental y por la literatura de destilación de conocimiento. El control por variables fijas es el enfoque canónico para comparaciones A/B. La principal incertidumbre reside en posibles interacciones entre componentes, pero esto es mitigable con validaciones posteriores y la conveniencia de extender el estudio debe validarse empíricamente sobre el corpus del proyecto.

6.6. Recomendación final

- Consolidar la definición de todos los componentes constantes (modelo *student*, dataset, hiperparámetros, métricas) antes de iniciar cualquier entrenamiento.
- Evitar modificar múltiples variables simultáneamente durante la comparación: usar datasets idénticos, mismas métricas y misma configuración de destilación.
- Planificar un *ablation study* complementario una vez obtenidos los resultados principales, para validar la robustez de los hallazgos ante variaciones en componentes del RAG.

7. Próximos pasos

- Definir el dataset específico y las métricas de evaluación concretas para ambas condiciones.

- Seleccionar y fijar el modelo *teacher* y *student*.
- Implementar el pipeline de destilación *baseline* como grupo de control.
- Implementar el pipeline de destilación con *teacher* RAG como grupo experimental.
- Ejecutar un piloto a pequeña escala para validar el diseño antes de la comparación completa.