

HU-SPIKE – Definición de criterios de éxito y umbrales de mejora para el estudio comparativo de destilación con RAG

Documento de síntesis, comparación y recomendación técnica

Autor	Andrés Pérez Quinchía	Fecha	22/03/2026
Sprint	1	Estado	Done

1. Descripción de la HU

Como investigador, **quiero** definir criterios de éxito y umbrales de mejora cuantificables, **para** determinar objetivamente si la destilación con RAG aporta beneficios significativos.

2. Objetivo de la HU

Establecer un marco de evaluación cuantitativo que permita determinar, de forma objetiva y reproducible, si la destilación guiada por un *teacher* con RAG produce un *student* significativamente mejor que la destilación *baseline*. Esto implica seleccionar las métricas de desempeño más adecuadas para el tipo de tarea, definir umbrales mínimos de mejora que representen una diferencia prácticamente relevante, y elegir los métodos estadísticos apropiados para validar que las diferencias observadas no se deban al azar.

3. Contexto

El proyecto contempla un experimento comparativo entre dos condiciones de destilación: *baseline* (*teacher* sin RAG) y experimental (*teacher* con RAG). Una vez ejecutado el experimento, se obtendrán resultados numéricos del rendimiento de ambos *students*. Sin embargo, sin criterios de éxito previamente definidos, la interpretación de esos resultados sería subjetiva: ¿una mejora de 0.5 puntos en ROUGE-L es relevante o trivial? ¿basta con que una métrica mejore, o deben mejorar varias simultáneamente?

Este spike aborda la definición previa de ese marco evaluativo. La decisión de métricas y umbrales debe tomarse antes de ejecutar el experimento, siguiendo buenas prácticas de diseño experimental, para evitar el sesgo de ajustar los criterios de éxito a posteriori (*p-hacking* o *outcome switching*).

El marco debe cubrir tres dimensiones: (1) métricas de calidad del texto generado por el *student*, (2) umbrales mínimos de mejora que representen una diferencia prácticamente relevante, y (3) métodos de validación estadística para confirmar que las diferencias no son producto del azar.

4. Criterios de aceptación

Código	Criterio
CA1	Debe existir un documento de síntesis que describa las métricas utilizadas en estudios similares y los criterios de éxito adoptados en dichos estudios.
CA2	Debe existir una matriz de decisión que compare distintos umbrales de mejora y su efecto en la significancia de los resultados.
CA3	Debe quedar documentada la decisión sobre las métricas finales y los umbrales de mejora seleccionados, con su justificación técnica.
CA4	Deben incluirse fuentes académicas o técnicas que respalden las métricas y umbrales seleccionados.

5. Análisis comparativo

Se analizaron cuatro familias de métricas para evaluar el desempeño del *student* destilado, considerando su adecuación al dominio legal en español y al tipo de tarea (generación de texto condicionado por contexto). Adicionalmente, se analizaron tres enfoques para definir umbrales de mejora y validación estadística.

5.1. A. Métricas basadas en *n*-grams: BLEU y ROUGE

BLEU (*Bilingual Evaluation Understudy*) mide la precisión de *n*-grams entre el texto generado y una referencia, penalizando respuestas excesivamente cortas mediante un factor de brevedad. ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*) complementa a BLEU midiendo el *recall* de *n*-grams, y ofrece variantes como ROUGE-1 (unigramas), ROUGE-2 (bigramas) y ROUGE-L (subsecuencia común más larga).

Su principal ventaja es la simplicidad de cálculo, la amplia adopción en la literatura y la facilidad de comparación con estudios previos. Sin embargo, ambas métricas capturan únicamente solapamiento léxico superficial: dos textos semánticamente equivalentes pero con vocabulario diferente pueden obtener puntuaciones bajas. En el dominio legal, donde la terminología es rígida y repetitiva, esta limitación es menos severa que en dominios creativos, lo que las hace razonablemente adecuadas para este proyecto.

5.2. B. Métricas semánticas: BERTScore

BERTScore utiliza *embeddings* contextualizados de modelos tipo BERT para calcular la similitud semántica entre el texto generado y la referencia, produciendo valores de precisión, *recall* y F1 a nivel de *tokens*. A diferencia de BLEU y ROUGE, captura equivalencias semánticas más allá del solapamiento léxico exacto.

Su fortaleza es que reconoce paráfrasis y variaciones de vocabulario que conservan el significado. Su principal desventaja es la dependencia del modelo de *embeddings* utilizado: si el modelo base no ha sido entrenado (o no tiene buena cobertura) en español jurídico, la calidad de la métrica puede degradarse. Además, BERTScore es computacionalmente más costoso que las métricas de *n*-grams y menos interpretable para audiencias no técnicas.

5.3. C. Métricas de calidad de respuesta (*LLM-as-a-Judge*)

Las métricas de calidad de respuesta evalúan dimensiones cualitativas del texto generado que las métricas de *n-grams* y semánticas no capturan. Se implementan mediante el paradigma *LLM-as-a-Judge*, donde un modelo evaluador (típicamente un LLM de mayor capacidad) califica cada respuesta en una escala numérica (e.g., 1–5) según criterios predefinidos. Las dimensiones más relevantes para este proyecto son:

- ***Factual Accuracy* (Precisión factual):** Evalúa si la información contenida en la respuesta es objetivamente correcta y verificable contra las fuentes del dominio. En el contexto legal, esto implica que artículos, fechas, entidades y relaciones normativas sean precisos.
- ***Correctness* (Corrección):** Mide si la respuesta aborda adecuadamente la pregunta planteada y llega a una conclusión lógicamente válida, más allá de que los datos individuales sean correctos.
- ***Clarity* (Claridad):** Evalúa si la respuesta está redactada de forma comprensible, bien estructurada y sin ambigüedades. Una respuesta puede ser factualmente correcta pero confusa en su presentación.
- ***Completeness* (Compleitud):** Mide si la respuesta cubre todos los aspectos relevantes de la consulta sin omisiones significativas.

Su principal ventaja es que capturan dimensiones de calidad que reflejan cómo un usuario final juzgaría la respuesta, y son especialmente relevantes en el dominio legal donde la precisión factual y la claridad son críticas. Su desventaja es que dependen de la calidad del modelo evaluador, introducen variabilidad entre ejecuciones, y requieren diseñar *prompts* de evaluación robustos y reproducibles. Además, son más costosas computacionalmente que las métricas automáticas tradicionales.

5.4. D. Métricas de *faithfulness* y *relevancy* (RAG-específicas)

Frameworks como DeepEval y RAGAS ofrecen métricas diseñadas para evaluar sistemas RAG: *faithfulness* (grado en que la respuesta es fiel al contexto recuperado), *answer relevancy* (qué tan pertinente es la respuesta a la consulta), *contextual recall* y *contextual precision*. Estas métricas evalúan la calidad del pipeline de recuperación y la coherencia entre contexto y generación.

Son valiosas para diagnosticar el componente RAG del *teacher*, pero no miden directamente la calidad del *student* destilado, que es el objetivo del experimento comparativo. Por tanto, se consideran métricas de diagnóstico complementarias, no criterios de éxito principales.

5.5. Matriz de comparación

Métricas consideradas

Código	Métrica
A	BLEU / ROUGE (basadas en <i>n-grams</i>)
B	BERTScore (semántica)
C	Factual Accuracy, Correctness, Clarity, Completeness (<i>LLM-as-a-Judge</i>)
D	Faithfulness / Answer Relevancy (RAG-específicas)

Comparación por criterios

Criterio	A	B	C	D	Observaciones
Adecuación al dominio legal	Alta	Media-Alta	Muy alta	Media	C evalúa dimensiones críticas en derecho (precisión factual, claridad); D evalúa el RAG, no el <i>student</i> .
Captura semántica	Baja	Alta	Alta	Media	B y C capturan significado; A depende del solapamiento léxico.
Costo computacional	Bajo	Alto	Alto	Alto	A es rápida; B, C y D requieren modelos adicionales.
Interpretabilidad	Alta	Media	Muy alta	Baja	C produce <i>scores</i> por dimensión (claridad, precisión, etc.); D requiere conocimiento de RAG.
Comparabilidad con literatura	Muy alta	Alta	Media	Baja	BLEU/ROUGE son estándar; C es emergente pero creciente; D es emergente.
Relevancia para el experimento	Alta	Alta	Muy alta	Baja	A, B y C miden calidad del <i>student</i> ; D mide calidad del <i>retrieval</i> .

Umbrales de mejora y validación estadística

Para determinar si la diferencia entre ambos *students* es significativa, se analizaron tres enfoques complementarios:

Enfoque	Descripción	Umbral propuesto
Umbral absoluto de mejora	Diferencia mínima en puntos de métrica que se considera prácticamente relevante.	$\geq 1,0$ punto en ROUGE-L; $\geq 1,0$ punto en BLEU; $\geq 0,5$ puntos en BERTScore F1.
Significancia estadística	Prueba de hipótesis para descartar que la diferencia sea producto del azar.	p-valor $< 0,05$ mediante <i>paired bootstrap resampling</i> (b = 10,000 iteraciones).
Tamaño del efecto	Magnitud estandarizada de la diferencia (Cohen’s <i>d</i>) para evaluar relevancia práctica independiente de la muestra.	$ d \geq 0,5$ (efecto moderado según Cohen, 1992).

5.6. Síntesis de enfoques analizados

BLEU y ROUGE. Métricas de solapamiento léxico ampliamente adoptadas. Son el estándar de facto en evaluación de generación de texto y permiten comparabilidad directa con la literatura. Su limitación es la insensibilidad semántica, pero en el dominio legal esto es menos problemático debido al vocabulario rígido.

BERTScore. Métrica semántica basada en *embeddings* contextualizados. Complementa a BLEU/ROUGE al capturar equivalencias semánticas más allá del léxico. Su costo computacional es mayor y su calidad depende del modelo base utilizado.

Métricas de calidad de respuesta (*LLM-as-a-Judge*). Evalúan dimensiones cualitativas críticas: precisión factual, corrección, claridad y completitud. Reflejan cómo un usuario final juzgaría la respuesta y son especialmente relevantes en el dominio legal. Su limitación es la dependencia del modelo evaluador y la variabilidad entre ejecuciones, que se mitiga con múltiples evaluaciones y *prompts* estandarizados.

Métricas RAG-específicas (*faithfulness, answer relevancy*). Útiles para diagnosticar el pipeline de recuperación del *teacher*, pero no miden la calidad del *student* destilado, que es el objetivo del experimento.

5.7. Referencias consideradas

- R1** Papineni, K., et al. (2002). *BLEU: a Method for Automatic Evaluation of Machine Translation*. ACL 2002.
- R2** Lin, C. Y. (2004). *ROUGE: A Package for Automatic Evaluation of Summaries*. ACL 2004.
- R3** Zhang, T., et al. (2020). *BERTScore: Evaluating Text Generation with BERT*. ICLR 2020.
- R4** Zheng, L., et al. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. arXiv:2306.05685.
- R5** Shah, M. S., et al. (2024). *DeepEval: Unit Testing for LLMs*. GitHub Repository.
- R6** Es, S., et al. (2023). *RAGAS: Automated Evaluation of Retrieval Augmented Generation*. arXiv:2309.15217.

- R7** Cohen, J. (1992). *A power primer*. Psychological Bulletin, 112(1), 155–159.
- R8** Koehn, P. (2004). *Statistical Significance Tests for Machine Translation Evaluation*. EMNLP 2004.

6. Resultado / Conclusión

6.1. Hallazgos principales

- Las métricas de calidad de respuesta vía *LLM-as-a-Judge* (*factual accuracy, correctness, clarity, completeness*) son las más adecuadas como criterios de éxito principales: capturan las dimensiones que un usuario final del dominio legal priorizaría y que las métricas de solapamiento léxico no detectan.
- ROUGE-L y BLEU son valiosas como métricas de soporte para garantizar comparabilidad con la literatura de destilación, pero por sí solas son insuficientes para evaluar calidad en el dominio legal.
- BERTScore F1 complementa el marco al capturar equivalencias semánticas, pero tampoco evalúa dimensiones como precisión factual o claridad.
- Las métricas RAG-específicas son útiles para diagnosticar el pipeline del teacher, pero no deben ser criterios de éxito del experimento comparativo entre students.
- La combinación de umbral absoluto + significancia estadística + tamaño del efecto, aplicada sobre las métricas *LLM-as-a-Judge*, proporciona un marco robusto que evita tanto falsos positivos como resultados prácticamente irrelevantes.

6.2. Decisión técnica

Se adoptará un marco de evaluación centrado en métricas de calidad de respuesta evaluadas mediante *LLM-as-a-Judge*, complementadas con métricas automáticas tradicionales para comparabilidad con la literatura. La razón principal de esta decisión es que en el dominio legal, lo que determina si un *student* es útil no es el solapamiento léxico con una referencia, sino la precisión factual, la corrección del razonamiento y la claridad de la respuesta: dimensiones que solo las métricas de calidad de respuesta capturan adecuadamente.

- **Métricas principales (*LLM-as-a-Judge*):** *Factual Accuracy, Correctness, Clarity y Completeness*. Cada respuesta del *student* será evaluada en escala 1–5 por un modelo evaluador de alta capacidad, usando *prompts* estandarizados con rúbricas detalladas por dimensión. Se ejecutarán múltiples evaluaciones por muestra (mínimo 3) para mitigar la variabilidad y se reportará el promedio por dimensión y un *score* agregado ponderado. *Factual Accuracy* tendrá mayor peso (40 %) dado que en el dominio legal la precisión factual es la dimensión más crítica; las demás dimensiones se distribuirán equitativamente (20 % cada una).
- **Métricas automáticas de soporte:** ROUGE-L F1 y BLEU-4 como métricas secundarias para comparabilidad con la literatura de destilación. BERTScore F1 (modelo multilingüe) como métrica semántica complementaria.
- **Umbral de mejora mínima:** $\geq 0,3$ puntos en el *score* agregado de calidad de respuesta (escala 1–5) como criterio principal. De forma secundaria, $\geq 1,0$ punto absoluto en ROUGE-L o BLEU-4.

- **Validación estadística:** *Paired bootstrap resampling* con $b = 10,000$ iteraciones y $p < 0,05$ aplicado tanto a las métricas *LLM-as-a-Judge* como a las métricas automáticas.
- **Tamaño del efecto:** Cohen's $d \geq 0,5$ (efecto moderado) sobre el *score* agregado de calidad de respuesta.
- **Criterio de éxito global:** La destilación con RAG se considerará exitosa si el *score* agregado de calidad de respuesta mejora por encima del umbral con significancia estadística y tamaño del efecto moderado, sin degradar ninguna dimensión individual (*factual accuracy, correctness, clarity, completeness*) más de 0.2 puntos. Las métricas automáticas (ROUGE-L, BLEU) deben mantener estabilidad o mejorar.

La decisión se justifica porque: (1) las métricas *LLM-as-a-Judge* son las que mejor reflejan cómo un usuario final (abogado, juez, investigador) evaluaría la calidad de una respuesta legal, priorizando precisión factual y claridad sobre solapamiento léxico; (2) el paradigma *LLM-as-a-Judge* ha demostrado alta correlación con evaluaciones humanas según Zheng et al. (2023) y Liu et al. (2023); (3) ROUGE-L y BLEU se mantienen como métricas de soporte para garantizar comparabilidad con la literatura de destilación; (4) la ponderación asimétrica (40% *factual accuracy*) responde a la criticidad del dominio legal, donde un error factual tiene consecuencias severas; y (5) la triple condición estadística previene tanto falsos positivos como resultados prácticamente irrelevantes.

6.3. Impacto en el proyecto

- Permite determinar de forma objetiva si el componente RAG en el *teacher* produce un *student* con mejores respuestas en las dimensiones que realmente importan al usuario final: precisión factual, corrección, claridad y completitud.
- Evita el riesgo de que mejoras en solapamiento léxico enmascaren degradaciones en calidad real de la respuesta (o viceversa).
- Proporciona un marco reutilizable y escalable para futuras iteraciones, ya que los *prompts* de evaluación pueden adaptarse a nuevas dimensiones sin cambiar la infraestructura.

6.4. Trade-offs

Qué se gana	Qué se sacrifica	Riesgos
Marco de evaluación objetivo, reproducible y multidimensional: combina métricas de solapamiento, semánticas y de calidad de respuesta.	Mayor complejidad en la evaluación (múltiples métricas y condiciones). Las métricas <i>LLM-as-a-Judge</i> introducen variabilidad y dependen del modelo evaluador.	Si el modelo evaluador tiene sesgos o pobre cobertura del español jurídico, las métricas de calidad de respuesta podrían ser poco confiables. El umbral absoluto podría necesitar calibración empírica sobre el corpus real.
Triple condición estadística que previene falsos positivos y resultados triviales.		

6.5. Nivel de confianza

Nivel de confianza: Medio-Alto. Las métricas automáticas seleccionadas (ROUGE-L, BLEU, BERTScore) están ampliamente respaldadas por la literatura. Las métricas de calidad de respuesta vía *LLM-as-a-Judge* son un enfoque emergente pero con creciente adopción y validación empírica. El enfoque de triple condición (umbral + p-valor + tamaño del efecto) es metodológicamente sólido. La principal incertidumbre reside en la calibración de umbrales y en la estabilidad del modelo evaluador, que deberán validarse empíricamente con un piloto sobre el corpus real del proyecto.

6.6. Recomendación final

- Ejecutar un piloto a pequeña escala para calibrar la variabilidad real de las métricas sobre el corpus legal del proyecto. Si la varianza es muy alta, el umbral de 1.0 punto podría necesitar ajuste.
- Registrar los criterios de éxito antes de ejecutar el experimento principal, como práctica de pre-registro experimental.
- Considerar la inclusión de una evaluación humana cualitativa como complemento en iteraciones futuras, especialmente si las métricas automáticas arrojan resultados ambiguos.

7. Próximos pasos

- Implementar el pipeline de cálculo de métricas automáticas (ROUGE-L, BLEU-4, BERTScore) sobre el conjunto de test definido.
- Diseñar y validar los *prompts* de evaluación para las métricas *LLM-as-a-Judge* (*factual accuracy, correctness, clarity, completeness*), incluyendo pruebas de consistencia inter-evaluador.
- Ejecutar el piloto de calibración para validar la estabilidad de todas las métricas y ajustar umbrales si es necesario.
- Documentar formalmente el pre-registro del experimento con los criterios de éxito definidos.
- Proceder con la ejecución del experimento comparativo una vez validado el marco de evaluación.