

HU-SPIKE - Métodos estadísticos para la asignación de pesos y agregación de dimensiones en evaluación LLM-as-a-Judge

Alejandro Tirado Ramirez

22 de marzo de 2026

Sprint 1	Estado Done
----------	-------------

1. Descripción de la HU

Como investigador, quiero identificar y analizar métodos estadísticos para asignar pesos a las dimensiones de evaluación LLM-as-a-Judge y comparar los resultados entre modelos, para evaluar y comparar de forma rigurosa los resultados obtenidos por los *students* destilados.

2. Objetivo de la HU

Seleccionar y justificar los métodos estadísticos que se utilizarán para: (1) asignar pesos a las dimensiones de evaluación del LLM-as-a-Judge (accuracy, relevance, completeness, clarity), (2) agregar los scores de múltiples dimensiones en un score compuesto comparable entre condiciones experimentales, y (3) determinar si las diferencias observadas entre el *student baseline* y el *student RAG* son estadísticamente significativas y prácticamente relevantes.

3. Contexto

El marco de evaluación del proyecto utiliza LLM-as-a-Judge con cuatro dimensiones de calidad de respuesta, cada una evaluada en escala 1-5. Se estableció una ponderación asimétrica: accuracy con 40 %, relevance con 30 %, completeness con 20 % y clarity con 10 %, justificada por la criticidad de la precisión factual en el dominio legal. Es necesario analizar formalmente estos métodos para asegurar que la conclusión sea robusta ante variaciones en los pesos.

4. Criterios de Aceptación

- **CA1:** Documento de síntesis sobre métodos estadísticos en evaluación multidimensional.
- **CA2:** Matriz de decisión que compare los métodos de asignación de pesos y agregación.
- **CA3:** Documentación de la decisión sobre los métodos seleccionados y su justificación técnica.
- **CA4:** Fuentes académicas que respalden los métodos elegidos.

5. Análisis Comparativo

5.1. Ponderación fija por criterio experto

Consiste en definir de antemano la importancia de cada dimensión. Accuracy recibe el peso mayor (40 %) por la naturaleza del ámbito legal. Es simple y transparente, pero requiere un análisis de sensibilidad para verificar que los resultados no dependan de valores arbitrarios.

5.2. Ponderación basada en datos: AHP y correlación

El *Analytic Hierarchy Process* (AHP) deriva pesos mediante comparaciones pareadas consistentes. Los métodos basados en correlación requieren evaluaciones humanas de referencia para medir cuánto influye cada dimensión en la calificación global.

5.3. Ponderación uniforme + análisis de sensibilidad

Asigna un 25 % a cada dimensión. No introduce sesgos iniciales, pero ignora que en la práctica algunas dimensiones son más críticas que otras para el usuario final.

5.4. Métodos de validación estadística

- **Paired Bootstrap Resampling:** Genera miles de variaciones aleatorias para verificar la estabilidad de la diferencia. No requiere normalidad.
- **Wilcoxon Signed-Rank Test:** Prueba no paramétrica para comparar condiciones sobre los mismos datos.
- **Paired t-test y Cohen's d:** Prueba clásica que permite medir el tamaño del efecto (relevancia práctica), asumiendo normalidad.

5.5. Matrices de comparación

Criterio	A (Fija)	B (AHP/Corr)	C (Uniforme)
Transparencia	Alta	Media	Muy alta
Justificación formal	Media	Alta	Baja
Datos previos	No	Sí	No
Robustez	Media	Media	Alta (vía sensibilidad)
Alineación dominio	Alta	Alta	Media

Cuadro 1: Comparación de métodos de ponderación.

Criterio	Bootstrap	Wilcoxon	t-test
Normalidad	No	No	Sí
Uso en NLP	Muy alto	Medio	Medio
Tamaño efecto	No nativo	No nativo	Cohen's d
Muestras pequeñas	Robusto	Robusto	Poco robusto

Cuadro 2: Comparación de métodos de validación estadística.

5.6. Referencias consideradas

- R1** Zheng, L. et al. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS 2023.
- R2** Liu, Y. et al. (2023). *G-Eval: NLG Evaluation Using GPT-4 with Better Human Alignment*. EMNLP 2023.
- R3** Li, D. et al. (2024). *From Generation to Judgment: Opportunities and Challenges of LLM-as-a-Judge*. arXiv:2411.16594.
- R4** Saaty, T. L. (1980). *The Analytic Hierarchy Process*. McGraw-Hill.
- R5** Cohen, J. (1992). *A Power Primer*. Psychological Bulletin, 112(1).
- R6** Berg-Kirkpatrick, T., et al. (2012). *An Empirical Investigation of Statistical Significance in NLP*. EMNLP 2012.
- R7** Dror, R. et al. (2018). *The Hitchhiker’s Guide to Testing Statistical Significance in NLP*. ACL 2018.
- R8** Gu, J. et al. (2025). *A Survey on LLM-as-a-Judge*. arXiv:2501.02106.

6. Resultado / Conclusión

6.1. Decisión Técnica

Se adopta la **Ponderación fija por criterio experto** con el score agregado calculado como:

$$S = 0,40 \cdot AC + 0,30 \cdot RE + 0,20 \cdot CM + 0,10 \cdot CL$$

Como validación estadística se utilizará **Paired bootstrap resampling** (10,000 iteraciones, $\alpha = 0,05$) y **Cohen’s d** para reportar el tamaño del efecto, requiriendo $|d| \geq 0,5$ para considerar la diferencia relevante.

6.2. Trade-offs

- **Qué se gana:** Marco robusto con verificación de sensibilidad y validación estándar en NLP.
- **Qué se sacrifica:** Mayor complejidad (múltiples escenarios de sensibilidad) y falta de pesos derivados empíricamente.
- **Riesgos:** Si la variabilidad del LLM evaluador es alta, las pruebas pierden poder. Se mitiga evaluando cada respuesta mínimo 3 veces.

7. Próximos Pasos

- Implementar en código el cálculo del score agregado ponderado y escenarios de sensibilidad.
- Implementar el pipeline de paired bootstrap y Wilcoxon.
- Ejecutar piloto para medir la variabilidad del LLM evaluador.